



CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA DE MINAS GERAIS  
ENGENHARIA DE COMPUTAÇÃO  
INTELIGÊNCIA ARTIFICIAL

## TRABALHO 2

**ÁLVARO AUGUSTO JOSÉ SILVA  
JOÃO PAULO DA CUNHA FARIA**

DIVINÓPOLIS - MG  
DEZEMBRO DE 2025

# Sumário

Resumo . . . . .	2
Parte 1: árvore, diagrama mermaid, exemplos de execução . . . . .	2
Parte 1: Árvore de Decisão Manual (Escala de Glasgow) . . . . .	2
1.1 Modelagem do Problema . . . . .	2
1.2 Diagrama de Fluxo (Mermaid) . . . . .	2
1.3 Exemplos de Execução . . . . .	3
Cenário A: Paciente com Trauma Leve . . . . .	3
Cenário B: Paciente com Trauma Grave . . . . .	4
Parte 2: Aprendizado Supervisionado (Kaggle) . . . . .	5
2.1 Descrição do Dataset . . . . .	5
2.2 Pré-processamento e Tratamento de Dados . . . . .	5
2.3 Resultados Individuais dos Algoritmos . . . . .	5
I. Support Vector Machine (SVM) . . . . .	5
II. K-Nearest Neighbors (KNN) . . . . .	6
III. Árvore de Decisão (Decision Tree) . . . . .	6
2.4 Análise das Figuras . . . . .	6
2.5 Compilado e Discussão de Resultados . . . . .	7
Parte 3: Algoritmo Genético (AG) — Distribuição de Antenas . . . . .	8
3.1 Modelagem e Abordagem . . . . .	8
3.2 Operadores Evolutivos e Configuração . . . . .	8
3.3 Função de Aptidão (Fitness) . . . . .	9
3.4 Impacto dos Parâmetros do Sistema . . . . .	9
3.5 Análise do Tempo de Execução . . . . .	9
3.6 Resultados e Análise Visual . . . . .	10
Parte 4: Inteligência de Enxame e Sistemas Imunológicos — PSO e CLONALG . . . . .	10
4.1 Detalhes de Implementação e Cenário Dinâmico . . . . .	11
4.2 Particle Swarm Optimization (PSO) . . . . .	11
4.3 Algoritmo de Seleção Clonal (CLONALG) . . . . .	11
4.4 Análise dos Resultados e Visualização . . . . .	12
4.5 Comparação Qualitativa entre as Abordagens . . . . .	13
Conclusões . . . . .	13

## Resumo

### Parte 1: árvore, diagrama mermaid, exemplos de execução

#### Parte 1: Árvore de Decisão Manual (Escala de Glasgow)

##### 1.1 Modelagem do Problema

Nesta etapa, foi implementado um sistema baseado em regras (árvore de decisão manual) para automatizar o cálculo da **Escala de Coma de Glasgow (ECG)**. O objetivo é auxiliar na triagem de pacientes com traumatismo cranioencefálico, classificando a gravidade da lesão com base em três critérios neurológicos distintos:

1. **Abertura Ocular (1 a 4 pontos):** Avalia o nível de consciência visual.
2. **Resposta Verbal (1 a 5 pontos):** Avalia a cognição e capacidade de comunicação.
3. **Resposta Motora (1 a 6 pontos):** Avalia a capacidade de obedecer a comandos e reflexos motores.

O algoritmo soma as pontuações obtidas em cada critério, gerando um resultado final entre 3 e 15. A classificação final segue a lógica implementada no código:

- **13–15 pontos:** Trauma Leve.
- **9–12 pontos:** Trauma Moderado.
- **3–8 pontos:** Trauma Grave (com alerta de intubação).

##### 1.2 Diagrama de Fluxo (Mermaid)

A estrutura lógica do algoritmo foi modelada utilizando a linguagem de diagramação Mermaid. O fluxo consiste em três blocos sequenciais de perguntas binárias (Sim/Não), onde a resposta afirmativa atribui uma pontuação imediata e encerra o bloco, enquanto a negativa leva à próxima pergunta de menor gravidade.

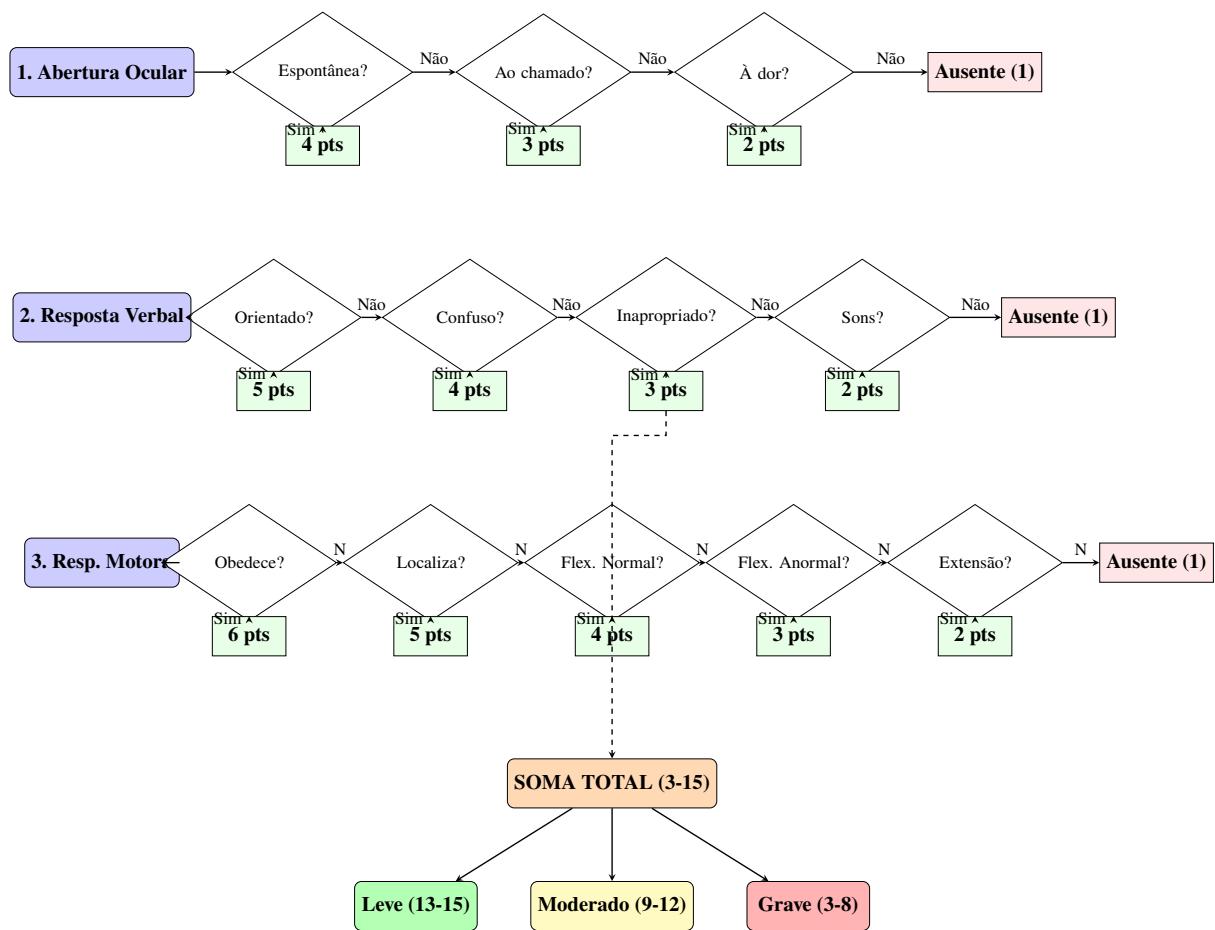


Figura 1 – Fluxograma da Escala de Glasgow (Layout Horizontal).

### 1.3 Exemplos de Execução

Abaixo são apresentados dois cenários de execução do algoritmo desenvolvido, demonstrando o funcionamento para diferentes gravidades de trauma.

#### Cenário A: Paciente com Trauma Leve

Neste exemplo, o paciente está consciente, orientado e responde a comandos. O sistema calcula a pontuação máxima (15).

```

1 =====
2   CALCULADORA DA ESCALA DE GLASGOW
3   Responda as perguntas com 's' ou 'n'
4 =====
5
6 --- 1. ABERTURA OCULAR ---
7 Abre os olhos espontaneamente? (s/n): s
8
9 --- 2. RESPOSTA VERBAL ---
10 O paciente est  orientado e conversa? (s/n): s
11

```

```

12 --- 3. RESPOSTA MOTORA ---
13 Obedece a comandos? (s/n): s
14
15 =====
16 RESULTADO FINAL: 15 PONTOS
17 CLASSIFICA 0: TRAUMA LEVE
18
19 Detalhamento: Ocular(4) + Verbal(5) + Motora(6)
20 =====

```

Listing 1 – Output do Terminal - Trauma Leve

**Cenário B: Paciente com Trauma Grave**

Neste exemplo, o paciente apresenta reações apenas a estímulos dolorosos e extensão anormal, caracterizando um quadro crítico que exige intubação.

```

1 =====
2   CALCULADORA DA ESCALA DE GLASGOW
3   Responda as perguntas com 's' ou 'n'
4 =====
5
6 --- 1. ABERTURA OCULAR ---
7 Abre os olhos espontaneamente? (s/n): n
8 Abre os olhos ao comando verbal? (s/n): n
9 Abre os olhos press o/dor? (s/n): s
10
11 --- 2. RESPOSTA VERBAL ---
12 O paciente est orientado e conversa? (s/n): n
13 A conversa confusa? (s/n): n
14 Usa palavras inapropriadas? (s/n): n
15 Emite sons inintelig veis? (s/n): s
16
17 --- 3. RESPOSTA MOTORA ---
18 Obedece a comandos? (s/n): n
19 Localiza o est mulo doloroso? (s/n): n
20 Apresenta flex o normal (movimento de retirada)? (s/n): n
21 Apresenta flex o anormal (decortica o)? (s/n): n
22 Apresenta extens o anormal (descerebra o)? (s/n): s
23
24 =====
25 RESULTADO FINAL: 6 PONTOS
26 CLASSIFICA 0: TRAUMA GRAVE
27 !!! ATEN 0: CONSIDERAR INTUBA 0 !!!
28
29 Detalhamento: Ocular(2) + Verbal(2) + Motora(2)
30 =====

```

---

Listing 2 – Output do Terminal - Trauma Grave

## Parte 2: Aprendizado Supervisionado (Kaggle)

### 2.1 Descrição do Dataset

Para esta etapa, o problema escolhido foi de **Classificação**. O conjunto de dados selecionado foi o **Heart Disease Dataset**, obtido via Kaggle.

- **Link de acesso:** <<https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>>
- **Objetivo:** Identificar a presença de doenças cardíacas através de indicadores clínicos.
- **Composição:** O dataset original possui 1025 instâncias com variáveis numéricas e categóricas.

### 2.2 Pré-processamento e Tratamento de Dados

Foram aplicados tratamentos essenciais para garantir a reproduzibilidade e eficácia dos modelos:

1. **Limpeza:** Verificação de integridade e confirmação de ausência de valores nulos.
2. **Escalonamento:** Uso de *StandardScaler* para normalizar os dados, prevenindo que atributos com escalas maiores dominem o cálculo de distância no KNN e SVM.
3. **Divisão da Base:** Separação estratificada em 80

### 2.3 Resultados Individuais dos Algoritmos

#### I. Support Vector Machine (SVM)

O SVM foi treinado com o kernel RBF. Embora tenha apresentado estabilidade durante a validação cruzada, obteve os resultados de acurácia mais conservadores do grupo.

- **Acurácia de Teste:** 0.64.
- **Cross-Validation Scores:** [0.67, 0.75, 0.63, 0.72, 0.71].
- **Média CV:** 0.70.

## II. K-Nearest Neighbors (KNN)

O modelo KNN foi otimizado através da busca pelo valor ideal de vizinhos ( $k$ ) que minimizasse o erro de validação.

- **Melhor K identificado:** 17.
- **Acurácia:** 0.73.
- **Precisão e Recall (Macro):** 0.73.

## III. Árvore de Decisão (Decision Tree)

A árvore de decisão apresentou o desempenho mais elevado em termos de acurácia bruta, mostrando-se eficaz na separação das classes de risco cardíaco.

- **Acurácia:** 0.76.
- **Precisão:** 0.81.
- **Recall:** 0.75.

### 2.4 Análise das Figuras

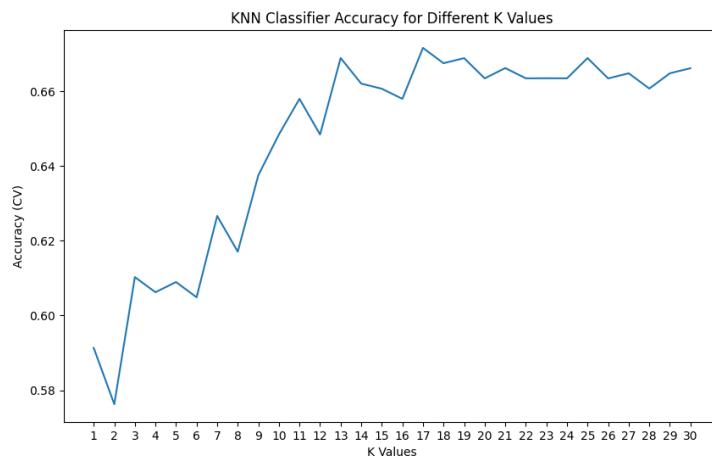


Figura 2 – Acurácia do KNN por valor de K.

**Descrição da Figura 2:** Este gráfico demonstra o comportamento do KNN conforme o número de vizinhos aumenta. Observa-se que valores muito baixos de  $k$  resultam em instabilidade. O ponto ideal foi fixado em  $k = 17$ , onde a acurácia atinge um platô de estabilidade antes de sofrer possíveis simplificações excessivas.

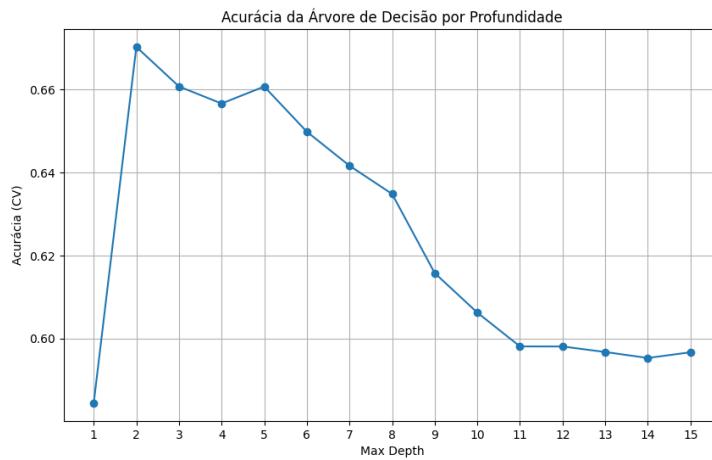


Figura 3 – Acurácia da Árvore de Decisão por Profundidade.

**Descrição da Figura 3:** A imagem ilustra a relação entre a profundidade máxima da árvore e a acurácia. Nota-se que o pico de desempenho ocorre em profundidade 2. Após esse ponto, a acurácia tende a cair, indicando que árvores mais profundas sofrem de *overfitting*, memorizando ruídos do treino em vez de padrões generalizáveis.

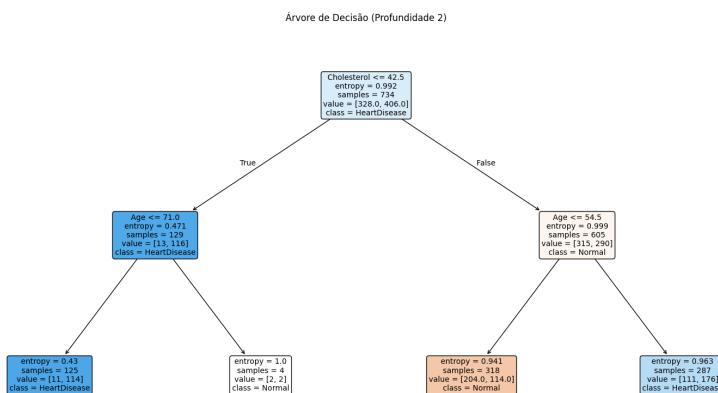


Figura 4 – Visualização da Estrutura da Árvore (Profundidade 2).

**Descrição da Figura 4:** Apresenta o modelo final de decisão. O nó raiz utiliza o nível de *Cholesterol* como critério primário de divisão, seguido pela *Age* (Idade). Esta visualização permite entender a hierarquia de importância das variáveis no diagnóstico clínico gerado pelo modelo.

## 2.5 Compilado e Discussão de Resultados

O processo de avaliação demonstrou que, para este dataset, modelos baseados em árvores são ligeiramente mais eficientes que modelos baseados em distância.

Tabela 1 – Tabela Comparativa Final das Métricas (Classificação).

Algoritmo	Acurácia	Precisão	Recall (Revocação)	F1-Score (Macro)
Árvore de Decisão	<b>0.76</b>	<b>0.81</b>	0.75	<b>0.76</b>
KNN ( $k = 17$ )	0.73	0.75	0.75	0.73
SVM (RBF)	0.64	0.66*	-	-

\*Valor referente à média da validação cruzada.

**Conclusão da Parte 2:** A **Árvore de Decisão** é recomendada como o modelo principal para este problema, pois obteve a melhor precisão (0.81), minimizando falsos positivos. O **KNN** mostrou-se uma alternativa robusta e equilibrada, enquanto o **SVM** exigiria um ajuste de hiperparâmetros (como busca por  $C$  e  $\gamma$ ) mais agressivo para atingir os patamares dos demais.

## Parte 3: Algoritmo Genético (AG) — Distribuição de Antenas

### 3.1 Modelagem e Abordagem

O problema abordado é uma adaptação do *Maximum Coverage Location Problem* (MCLP). Diferente de problemas de otimização em espaços discretos, este modelo opera em um plano contínuo, onde o objetivo é encontrar a melhor configuração conjunta de até 10 antenas para maximizar o atendimento aos clientes.

A representação cromossômica (genótipo) consiste em um vetor de números reais e booleanos, onde cada antena é definida por três genes: coordenada X, coordenada Y e um bit de ativação. A escolha do Algoritmo Genético justifica-se pela natureza não linear da função de aptidão e pela alta dimensionalidade do espaço de busca (10 antenas×3 genes cada=30 dimensões).

### 3.2 Operadores Evolutivos e Configuração

Para garantir a exploração (*exploration*) e o aproveitamento (*exploitation*) do espaço de busca, foram implementados os seguintes operadores:

- **Seleção:** Foi utilizado o método de **Seleção por Torneio** (tamanho 3). Este método foi escolhido por manter uma pressão seletiva constante e evitar a dominância prematura de indivíduos “super-fit”, o que é comum em problemas de localização espacial.
- **Cruzamento (Crossover):** Aplicou-se o **Cruzamento de Ponto Único** com uma taxa de **80%**. Dada a estrutura do cromossomo organizada por blocos de antenas, este operador permite que subconjuntos de posicionamentos bem-sucedidos sejam transmitidos integralmente para os descendentes.
- **Mutação:** Utilizou-se a **Mutação Gaussiana** para as coordenadas (ajuste fino de posição) e **Bit-flip** para o estado de ativação, com uma taxa de **10%** por gene. Essa taxa relativamente

alta é necessária para evitar que o algoritmo fique preso em ótimos locais, especialmente quando as antenas convergem para o mesmo cluster de clientes.

- **Critério de Parada:** O algoritmo encerra sua execução após um limite fixo de **100 gerações** ou caso não haja melhoria no melhor indivíduo da população (**estagnação**) por 20 gerações consecutivas.

### 3.3 Função de Aptidão (Fitness)

A função de *fitness* foi desenhada para equilibrar três objetivos conflitantes:  $\text{Fitness} = C(S)(N) \text{Penalidades}$   
Onde:

- C: Número de clientes cobertos (distância 30m de uma antena ativa).
- S: Sobreposição de sinal entre antenas (penalidade para evitar redundância).
- N: Número de antenas ativas (incentivo à economia de recursos).
- **Penalidades:** Atribuídas a antenas posicionadas fora do raio limite de 100m para garantir a viabilidade geográfica.

### 3.4 Impacto dos Parâmetros do Sistema

A dinâmica de convergência é diretamente afetada pelas constantes do sistema:

- **Quantidade de Clientes (N=80):** Define a "resolução" do problema. Uma densidade maior de clientes permite que o AG identifique *clusters* populacionais com mais clareza.
- **Raio de Alcance (30.0m):** Determina a sensibilidade da solução. Um raio curto exige precisão cirúrgica no posicionamento, enquanto um raio longo facilita a cobertura, mas aumenta o risco de sobreposições ineficientes.
- **Raio do Campo (100.0m):** Atua como a restrição de contorno, definindo o grau de dificuldade do "empacotamento" espacial.

### 3.5 Análise do Tempo de Execução

O tempo de execução é influenciado pela complexidade computacional da função de aptidão, estimada em  $O(GPCA)$ , onde G são gerações, P a população, C os clientes e A as antenas. A necessidade de calcular a distância euclidiana entre cada cliente e cada antena ativa para todos os indivíduos de todas as gerações é a principal causa do custo computacional elevado.

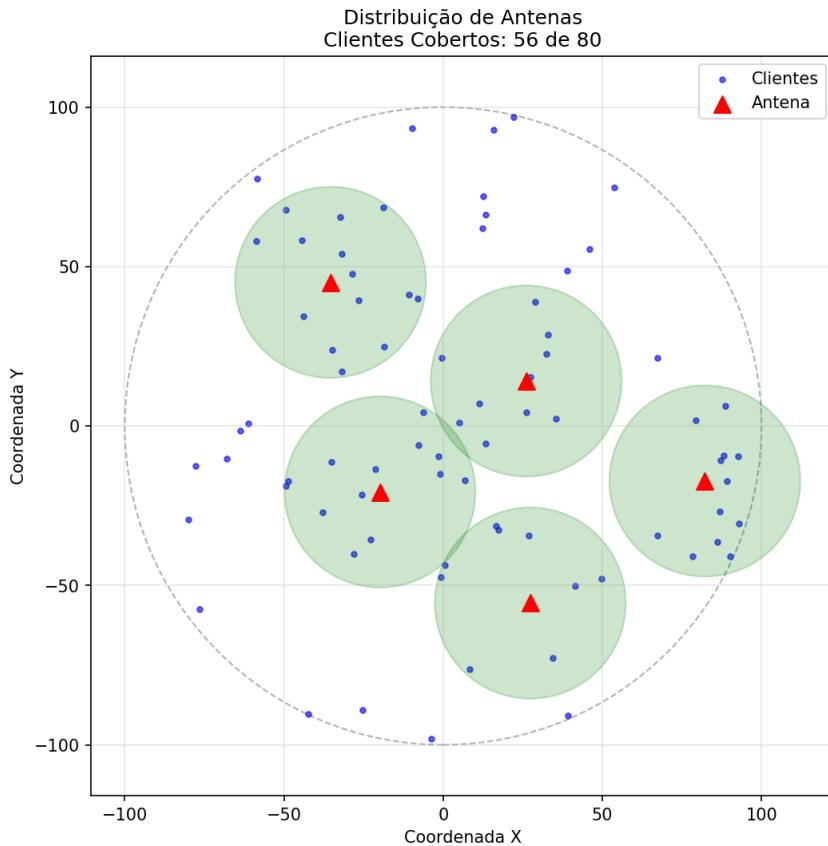


Figura 5 – Distribuição final das antenas e clientes no plano operacional.

### 3.6 Resultados e Análise Visual

O experimento resultou na cobertura de 56 dos 80 clientes (70%

A análise da Figura 5 revela comportamentos estratégicos do algoritmo:

- **Clusterização Tática:** As antenas foram posicionadas em zonas de alta densidade. O AG optou por ignorar clientes isolados nas bordas para maximizar o retorno sobre o uso de cada antena.
- **Otimização de Ativos:** Mesmo com um limite de 10 antenas, o algoritmo utilizou apenas 5 unidades ativas, demonstrando que a penalidade por excesso de equipamentos foi eficaz.
- **Conformidade Geométrica:** Todas as antenas foram mantidas dentro da fronteira operacional, validando o sistema de penalidades por coordenadas inválidas.

## Parte 4: Inteligência de Enxame e Sistemas Imunológicos — PSO e CLONALG

Nesta etapa, o problema de otimização de cobertura foi abordado através de duas meta-heurísticas distintas: o *Particle Swarm Optimization* (PSO), baseado no comportamento social de bandos, e o *CLONALG*, inspirado na teoria da seleção clonal do sistema imunológico biológico.

#### 4.1 Detalhes de Implementação e Cenário Dinâmico

Diferente das abordagens estáticas, a implementação foi projetada para testar a robustez dos algoritmos em cenários mutáveis.

- **Dinamismo dos Clientes:** Em cada execução do código, as posições dos 80 clientes são geradas de forma aleatória dentro do campo de  $100 \times 100$  metros. Isso garante que o algoritmo não esteja "viciado" em uma topologia específica, exigindo uma capacidade real de generalização.
- **Representação do Espaço de Busca:** O vetor de decisão (partícula ou anticorpo) é estruturado como um arranjo unidimensional de tamanho  $2N$  (onde  $N$  é o número de antenas), contendo as coordenadas  $(x, y)$  de cada equipamento.
- **Restrição de Margem:** Foi implementada uma zona de exclusão de 10 metros nas bordas do terreno ( $LIMITE\_MIN = 10$ ,  $LIMITE\_MAX = 90$ ). Essa restrição força os algoritmos a encontrar soluções que cubram clientes periféricos sem posicionar as antenas fora da área útil permitida, simulando limitações reais de instalação em propriedades privadas ou áreas de preservação.

#### 4.2 Particle Swarm Optimization (PSO)

O PSO baseia-se na premissa de que a inteligência emerge da colaboração social. Cada "partícula" voa pelo espaço de busca ajustando sua trajetória com base em:

1. Sua própria inércia ( $w = 0.7$ );
2. Sua melhor experiência individual ( $pbest$ );
3. A melhor experiência compartilhada pelo grupo ( $gbest$ ).

A aplicação do *clipping* (função `np.clip`) foi fundamental para manter a viabilidade das soluções dentro da margem de 10m. O PSO demonstrou uma capacidade excepcional de "sugar" as antenas em direção aos centros de massa dos clientes, apresentando uma convergência fluida devido à natureza vetorial contínua do movimento das partículas.

#### 4.3 Algoritmo de Seleção Clonal (CLONALG)

O CLONALG aborda o problema tratando cada configuração de antenas como um "anticorpo". A eficácia (aptidão) da solução determina sua taxa de reprodução:

- **Clonagem:** Soluções com alta cobertura são clonadas extensivamente.
- **Hipermutação Somática:** Os clones sofrem mutações com uma taxa inversamente proporcional à sua aptidão. Isso significa que soluções quase perfeitas sofrem ajustes finos

(mutação baixa), enquanto soluções ruins são radicalmente alteradas para explorar novas áreas do mapa.

Essa dualidade entre exploração e aproveitamento permitiu que o CLONALG mantivesse uma diversidade populacional alta, evitando que todas as antenas se aglomerassesem em um único ponto de alta densidade de clientes.

#### 4.4 Análise dos Resultados e Visualização

Ambos os algoritmos atingiram a marca de **100,00% de cobertura** nos testes realizados, demonstrando uma superioridade prática em relação ao Algoritmo Genético convencional para este número específico de sensores.

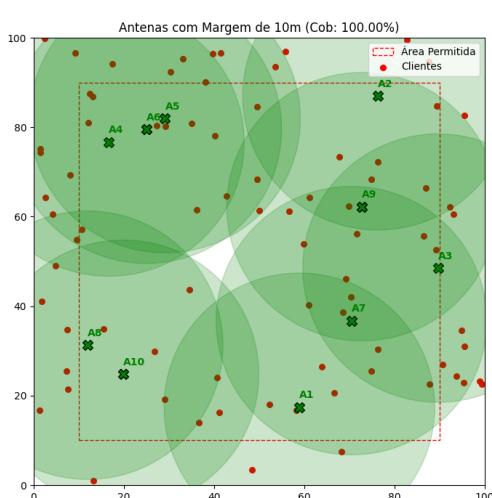


Figura 6 – Resultado final da otimização via PSO.

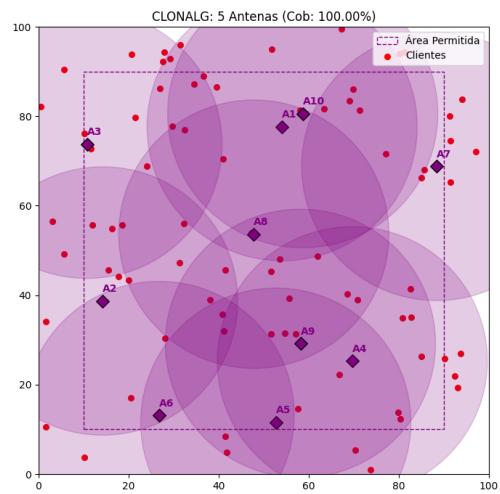


Figura 7 – Resultado final da otimização via CLONALG.

As Figuras 6 e 7 ilustram as estratégias adotadas:

- **Geometria de Cobertura:** Observa-se que os algoritmos posicionam as antenas de forma a "envelopar" os aglomerados de clientes. As áreas de sobreposição (tonalidades mais escuras de verde/roxo) ocorrem apenas onde a densidade de clientes é tão dispersa que uma única antena não seria suficiente.
- **Uso da Margem:** É visível o respeito à linha tracejada vermelha/roxa. Mesmo com clientes localizados próximos às coordenadas (0,0) ou (100,100), as antenas permanecem dentro do limite de 10m, utilizando o alcance do sinal ( $RAIO = 15m$ ) para "alcançar" os clientes externos sem violar a restrição de posicionamento físico.
- **Distribuição de Esforço:** No CLONALG, as antenas rotuladas (A1 a A10) mostram uma distribuição bem distribuída, preenchendo vazios espaciais de forma quase geométrica, o que minimiza o desperdício de sinal em áreas sem clientes.

#### 4.5 Comparação Qualitativa entre as Abordagens

Apesar de compartilharem o mesmo objetivo e restrições geométricas, as três abordagens apresentam comportamentos distintos na forma como "enxergam" e exploram o plano operacional:

- **Exploração vs. Refinamento:** O **Algoritmo Genético (AG)** baseia sua busca na recombinação de soluções. Isso permite saltos globais no espaço de busca, mas pode causar a fragmentação de boas configurações geográficas durante o *crossover*. Em contraste, o **PSO** apresenta um movimento "fluido" e vetorial; as antenas deslizam pelo plano como um bando, o que facilita o ajuste fino em torno dos aglomerados de clientes. Já o **CLONALG** utiliza a hipermutação como uma ferramenta de precisão, refinando localmente cada antena após identificar uma área de interesse.
- **Tratamento de Zonas de Sombra:** O AG demonstrou uma tendência a priorizar grandes concentrações de clientes, aceitando deixar indivíduos isolados em "zonas de sombra" para manter a economia de recursos e evitar penalidades. Por outro lado, as técnicas da Seção 4 (PSO e CLONALG) mostraram-se mais resilientes na busca pela cobertura total. Elas conseguem "esticar" a configuração das antenas até os limites da margem permitida, garantindo que mesmo os clientes periféricos sejam atendidos sem violar as restrições de borda.
- **Coordenação Coletiva:** No PSO, existe uma consciência social imediata (através do *gbest*), onde todas as antenas de todas as partículas colaboram para cobrir o vácuo deixado pelas outras. No AG, essa coordenação é indireta e baseada na sobrevivência do mais apto, o que pode levar a uma convergência prematura em soluções que cobrem bem o centro, mas negligenciam as extremidades.
- **Adaptabilidade ao Cenário Dinâmico:** Devido ao fato de os clientes serem reposicionados a cada execução, o PSO e o CLONALG demonstraram maior robustez. Enquanto o AG exige um ajuste mais fino de suas taxas de mutação e seleção para não se "viciar" em uma topologia, a memória imunológica do CLONALG e a inércia social do PSO permitem uma reconfiguração espacial mais rápida e eficiente diante de novas distribuições de clientes.

Esta comparação evidencia que, para problemas de localização contínua com alta exigência de cobertura (100

## Conclusões

O trabalho evidenciou que, para problemas de localização contínua com restrições de margem, algoritmos baseados em enxames e sistemas imunes oferecem uma estabilidade de convergência superior. Enquanto o AG tradicional pode sofrer com a "quebra" de boas soluções durante o

*crossover*, o movimento contínuo do PSO e a hipermutação controlada do CLONALG permitem um refinamento mais preciso das coordenadas, resultando em cobertura total do cenário proposto.